obligatorisk oppgave statistikk

Kristian Skibrek

all kode for oppgaven er tilgjengelig på github

Oppgave 1

```
import pandas as pd

varme = pd.read_csv("./varme.csv")
kulde = pd.read_csv("./kulde.csv")
```

forklaring av kode:

Jeg lager dataframes av csv filene med pandas read_csv metode

Oppgave 2

```
varme["Timestamp"] = pd.to_datetime(varme["Timestamp"], format="%d-%b-%y
%H:%M:%S")
varme.at[0, "Timestamp"] = varme.at[0, "Timestamp"] -
pd.DateOffset(months=1)
varme['maaned'] = varme['Timestamp'].dt.to_period('M')
maaneder_v = varme.groupby('maaned').tail(1)
maaneder_v.loc[:, 'Value (MW-hr)'] = maaneder_v['Value (MW-hr)'].diff()
maaneder_v = maaneder_v.drop(0)

plt.plot(list(range(0, len(maaneder_v))), maaneder_v["Value (MW-hr)"])

plt.xlabel("dato")
plt.ylabel("forbruk MW-hr")
plt.xticks(list(range(0, 12)), ["Jan", "Feb", "Mar", "Apr", "May",
"Jun", "Jul", "Aug", "Sep", "Oct", "Nov", "Dec"])
plt.grid()
plt.show()

plt.show
```

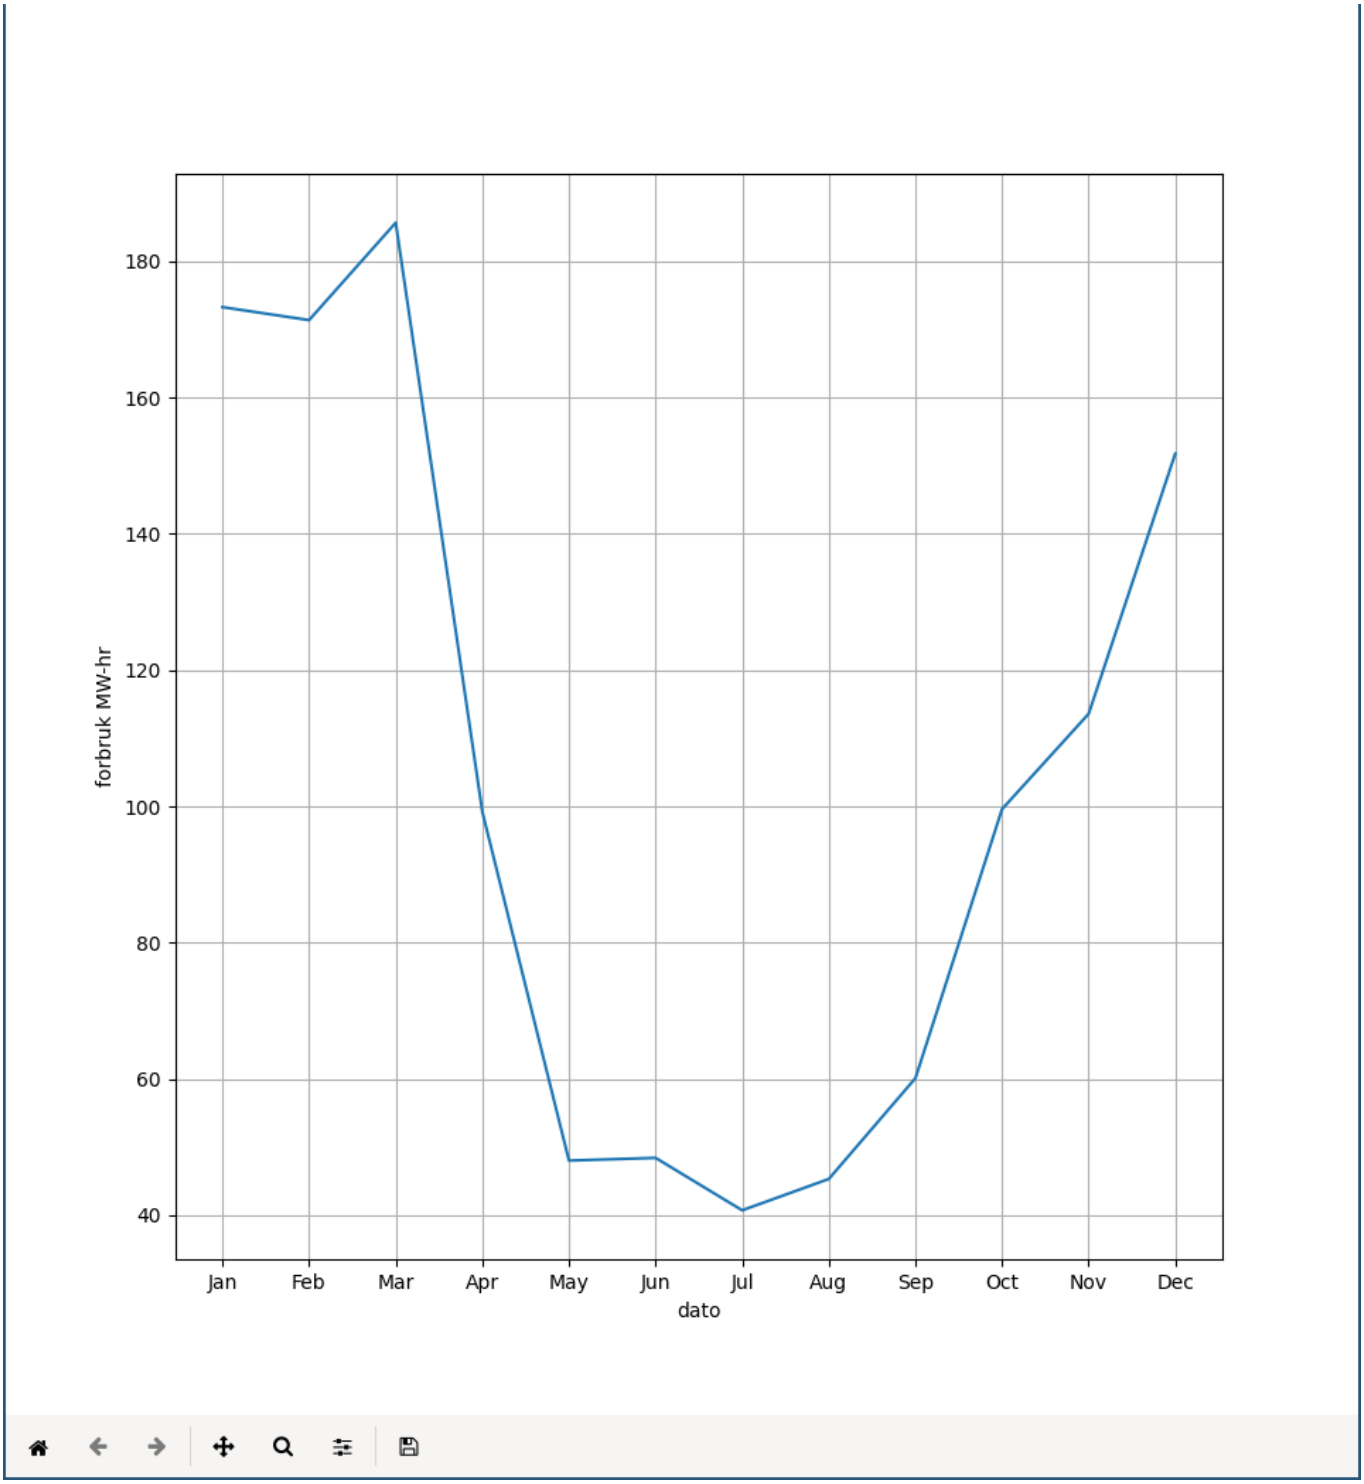

forklaring av kode

jeg finner forbruket per måned ved å ta forbruket på slutten av måneden og trekke fra forbruket på slutten av forrige måned. Jeg finner forbruket på slutten av hver måned ved å gi hver rad en kollonne for måneden den tilhører med to_period('M') og velger så den siste av hver måned med .groupby('maaned').tail(1). Jeg finner forskjellen mellom forbruket i hver rad med maaneder['Value (MW-hr)'].diff(). For å få en gyldig verdi for

januar sier jeg at den hører til måneden før og fjerner den igjen før jeg plotter (fordi første raden i dataframen til .diff blir NaN).

kilder jeg brukte for å komme fram til denne koden:

finn differanse mellom hver linje i pandas dataframe

gruppere rader i dataframe

offset dato for rad i dataframe

finn periode for rad i dataframe

Oppgave 3

```
varme['dag'] = varme['Timestamp'].dt.to_period('D')
dager_v = varme.groupby("dag").tail(1)
dager_v.loc[:,"Value (MW-hr)"] = dager_v['Value (MW-hr)'].diff()

dager_jan = dager_v.loc[
(dager_v['Timestamp'] > "2018-01-01") &
(dager_v['Timestamp'] < "2018-01-31")]
dager_jul = dager_v.loc[
(dager_v['Timestamp'] > "2018-07-01") &
(dager_v['Timestamp'] < "2018-07-31")]

dager_jan.plot.scatter("Timestamp", "Value (MW-hr)")
plt.gca().xaxis.set_major_locator(DayLocator())
plt.gca().xaxis.set_major_formatter(DateFormatter("%d"))
plt.grid()

dager_jul.plot.scatter("Timestamp", "Value (MW-hr)")
plt.gca().xaxis.set_major_locator(DayLocator())
plt.gca().xaxis.set_major_formatter(DateFormatter("%d"))
plt.grid()

plt.show()
```

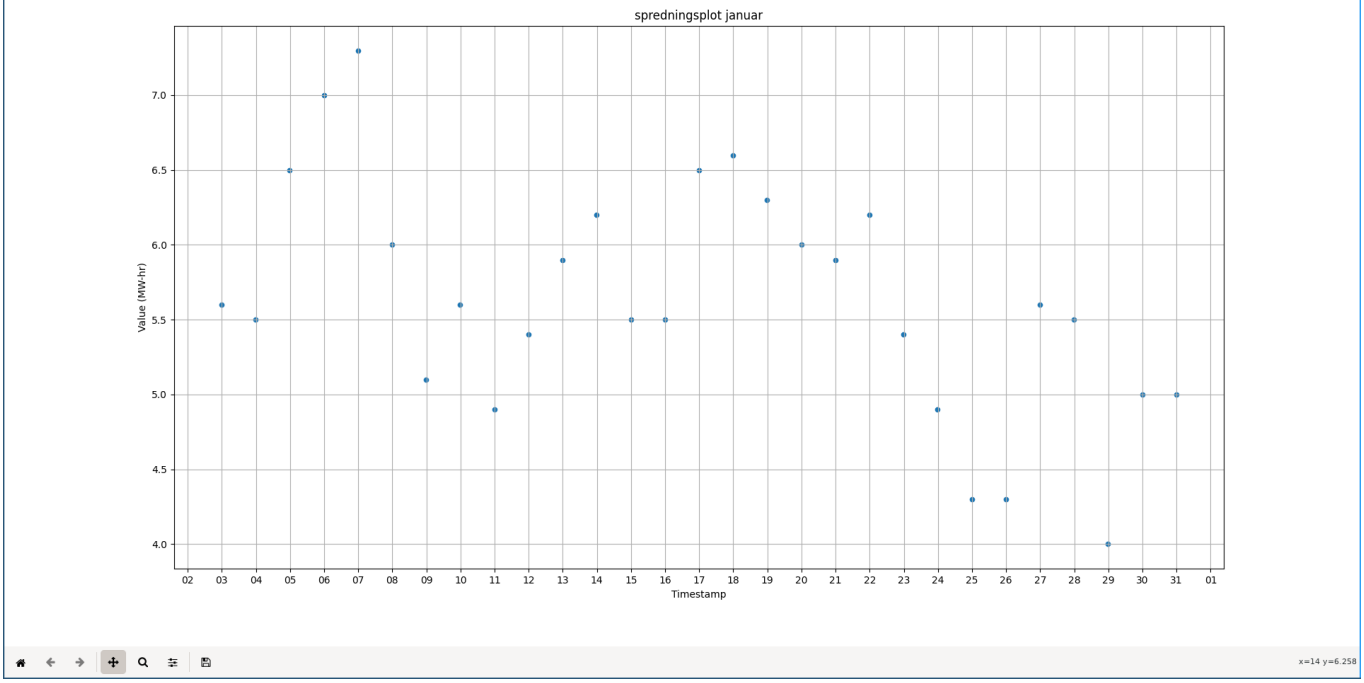

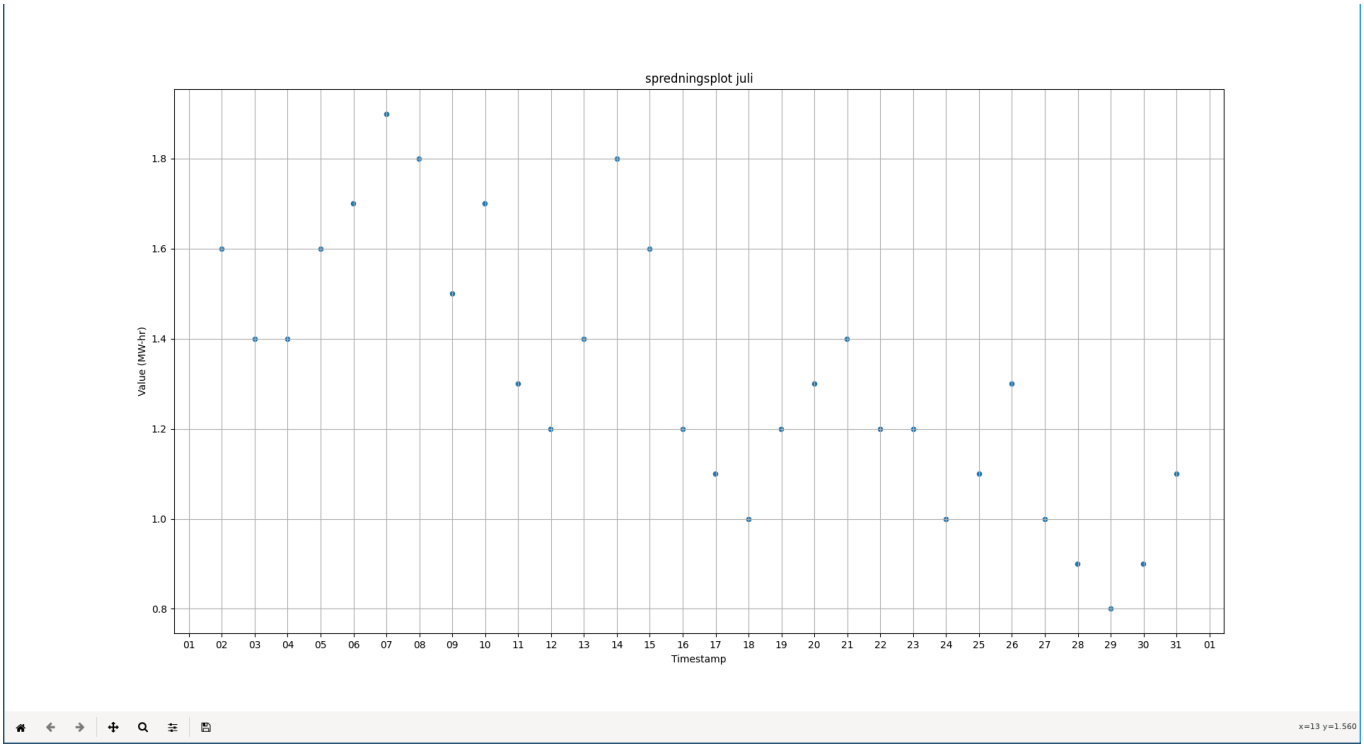

forklaring av kode

jeg bruker samme teknikker som i forrige oppgave, men gir varme dataframen en kolonne for dag også. Jeg lager så en ny dataframe hvor jeg filtrerer ut kun timestamps om hører til januar og juli.

kilder jeg brukte for å komme fram til denne koden:

boolean masking for å filtrere dataframes

datodager på x aksen

Oppgave 4

```
print(np.mean(dager_jan["Value (MW-hr)"]))
print(np.mean(dager_jul["Value (MW-hr)"]))
print(np.std(dager_jan["Value (MW-hr)"], ddof=1))
print(np.std(dager_jul["Value (MW-hr)"], ddof=1))
```

ouput:

```
5.60333333333333
1.320000000000012
0.7919784624959691
0.2952497481677353
```

forklaring av kode

jeg bruker funksjoner fra numpy for å regne ut gjennomsnitt og standardavvik.

numpy mean

Oppgave 5

ddof står for *"delta degrees of freedom"*. Bruken forklarest lettest ved å vise hvor den kommer inn i formelen for standardavviket:

$$\sqrt{\sum \frac{\overline{x} - x_i)^2}{n - \mathrm{ddof}}}$$

ved å sette ddof til 1 får vi divisjon med $n - 1$ istedenfor n. i vårt tilfelle er det n-1 vi vil ha fordi på grunn av antallet uavhengige differanser. Dette kalles presis utvalgsvarians.

numpy standard deviation
wiki standard deviation

Oppgave 6

```
plt.boxplot([dager_jan["Value (MW-hr)"], dager_jul["Value (MW-hr)"]])
plt.xticks([1, 2], ["jan", "jul"])
plt.ylabel("MW-hr")
```

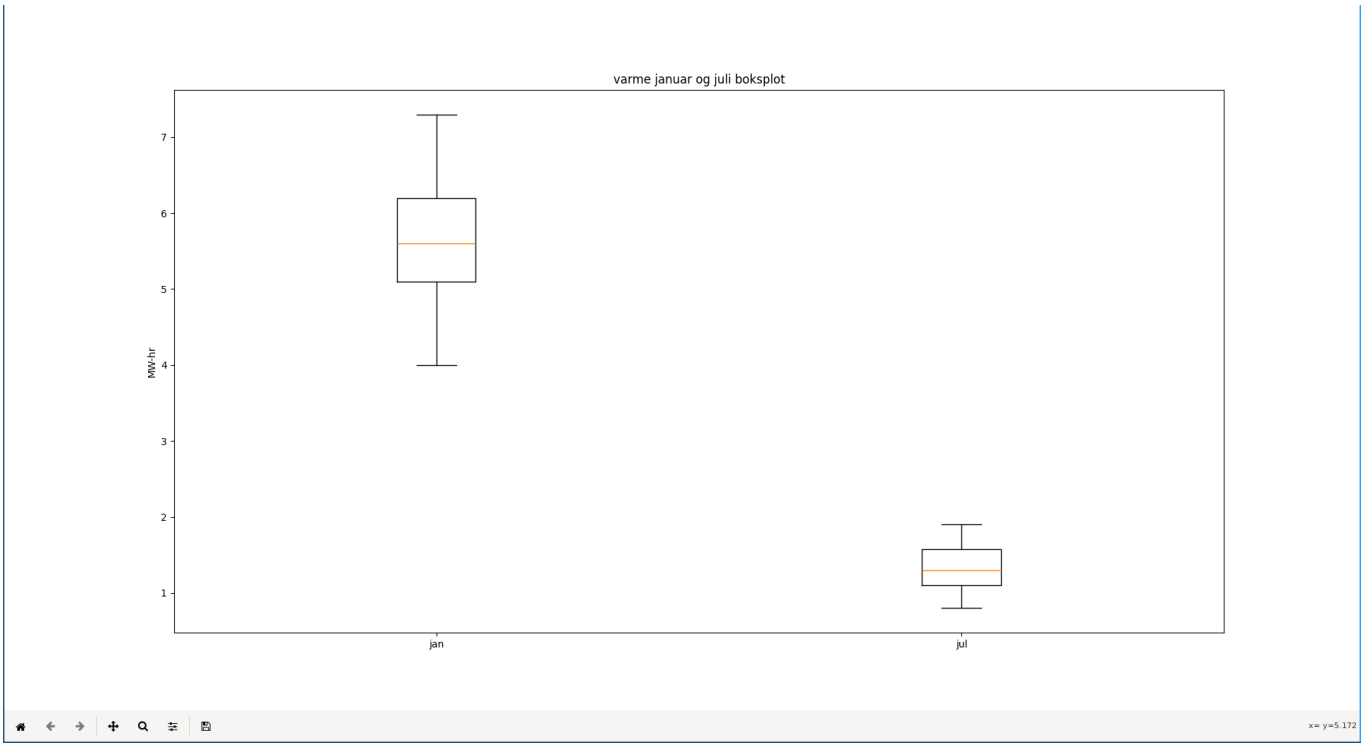

forklaring av kode

for å plotte dagene som boksplot bruker jeg [matplotlib.pyplot.boxplot]

Oppgave 7

```
dager_v.drop(0).plot.hist()
plt.ylabel("frekvens")
plt.xlabel("MW-hr")
```

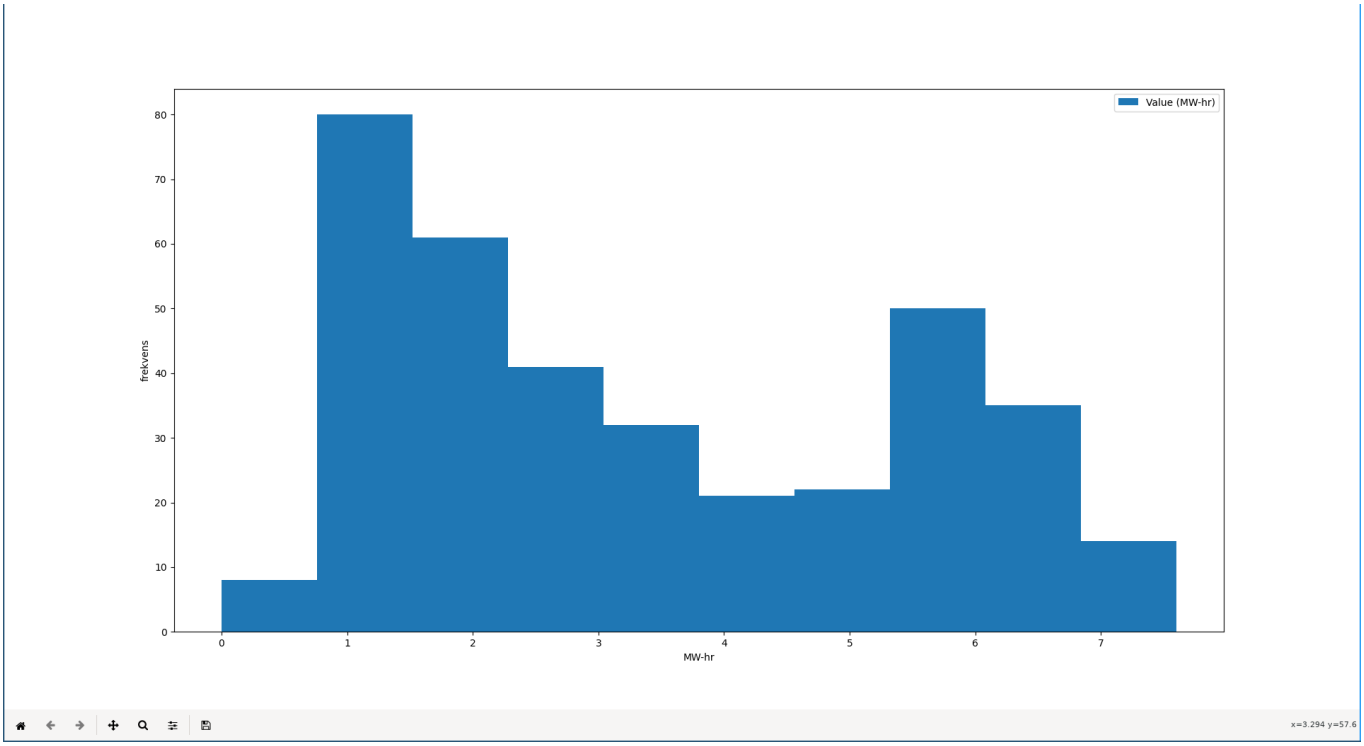

forklaring av kode:

Jeg bruker dataframes innebygde abstraksjon av matplotlib for å plotte funksjonen. jeg dropper første kollononne fordi det er en kopi av den første målingen satt til dagen før (se tidligere oppgave)

Oppgave 8

```
# lage dataframe for dagsforbruk av kjøling
kulde["Timestamp"] = pd.to_datetime(kulde["Timestamp"], format="%d-%b-%y
%H:%M:%S")
kulde['dag'] = kulde['Timestamp'].dt.to_period('D')
dager_k = kulde.groupby("dag").tail(1)
dager_k.loc[:,"Value (MW-hr)"] = dager_k['Value (MW-hr)'].diff()

plt.plot(sorted(dager_k["Value (MW-hr)"], reverse=True),
label="kjøling")
plt.plot(sorted(dager_v["Value (MW-hr)"], reverse=True), label="varme")
plt.ylabel("MW-hr")
plt.legend()
plt.show()
```

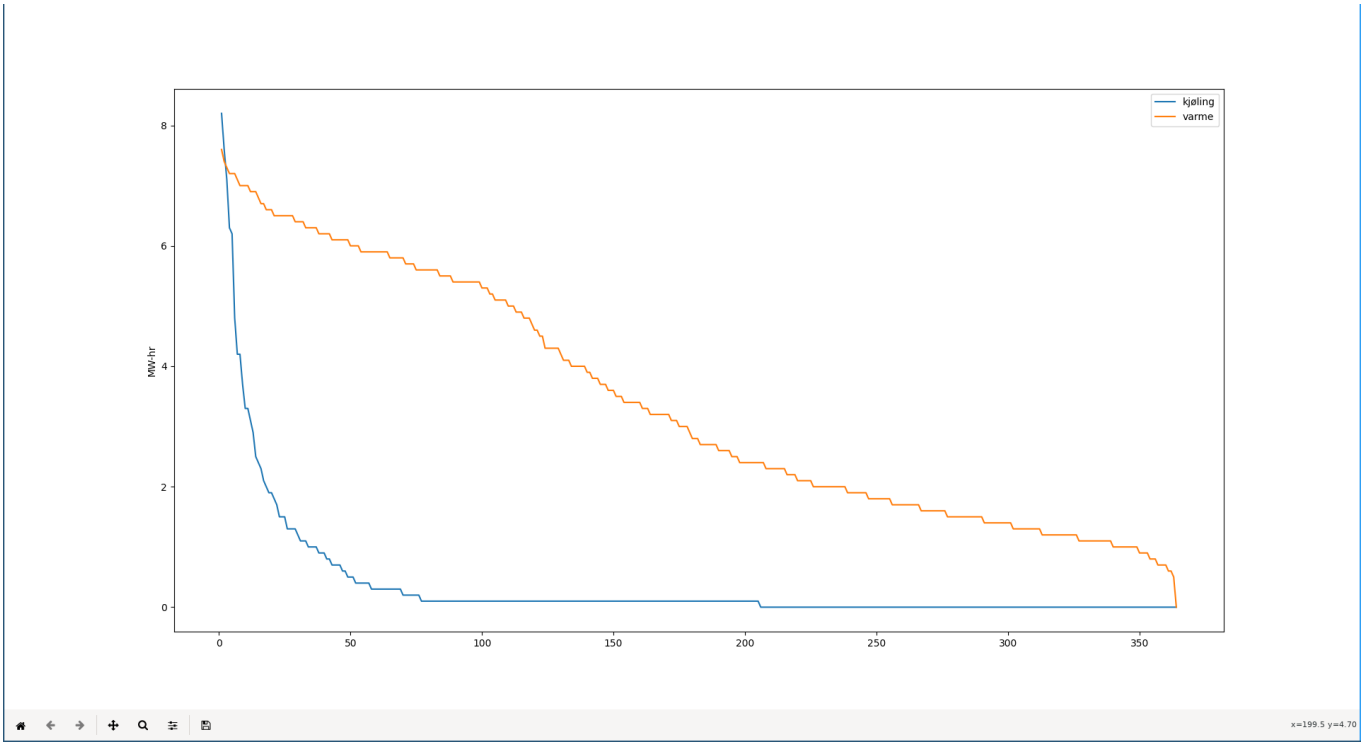

forklaring av kode:

jeg lager først en dataframe for kjøling, så plotter jeg dem og sorterer etter bruken av mw i baklengs ordre, så det største kommer først.

Oppgave 9

jeg fant ingen gode kilder på hva et persentilplott er, googling ga ingen goder resultater, og ordet ser ikke ut til å være nevnt i boken heller, jeg måtte derfor (i tillegg til kildene nevnt i teksten under) ta i bruk løsningsforslaget for å se om jeg var på rett spor med svaret mitt.

jeg går utifra at persentil p[engelsk er persetnile og bruker wikipedias definisjon av persentiler og How to Construct a Percentile Graph for å komme til konklusjonen at persentiler måler hvor stor del av det totale uvalget hver verdi er. Det er altså dette som plottes på y-aksen og på x aksen har man selve verdien. Dette er altså i motsetning til varighetskurven som har mw på y aksen og dag på x-aksen.

Oppgave 10

Varighetskurven sier meg at det brukes mer strøm på varme enn kjøling. Histogrammet har to topper på rundt 6 og 1 mw-hr, noe som også reflekteres i varighetskurven, siden det er flatepartier her. Dette betyr at det har vært mange dager med 1 og 6 mw-hr forbruk.